



یادگیری نیمه نظارتی با استفاده از دانشجویان نويزدار

راشد اکبری، دانشجوی کارشناسی ارشد، akbari.r@qut.ac.ir

عبدالرضا رسولی کناری، دکتری و استادیار، rasouli@qut.ac.ir

مرتضی محجل کفشدوز، دکتری و استادیار، mohajjel@qut.ac.ir

چکیده

برای موفقیت یادگیری عمیق^۲ وجود منابع داده‌های بزرگی که توسط متخصص و با صرف هزینه برچسب گذاری شده اند، ضروری هستند. اما زمانی که برچسب زنی دادگان، هزینه بر است، آموزش شبکه های عمیق با یک مجموعه کوچک برچسب دار، معمولاً منجر به عملکرد قابل قبولی نمی شود. هدف از یادگیری نیمه نظارتی^۳ به کارگیری داده های بدون برچسب رهاسده ای است که به راحتی می توان آنها را گردآوری کرد. الگوریتم های نیمه نظارتی جدید که مبتنی بر افزون سازی داده ها^۴ هستند توانسته اند به پیشرفت های جدیدی در این عرصه دست یابند. در این مقاله، با استفاده از الگوریتم دانشجویان نويزدار^۵ بر روی داده های کم با استفاده از داده های بدون برچسب دقت مدل را بالا برده و با مشکلات ناشی از داده های کم فایق آید. روش پیشنهادی، مدل را تشویق می کند با آموزش دانشجویان مختلف خطای کلاس بندی را کاهش داده و با انجام این عمل به صورت متوالی، به واسطه خودآموزی بر روی داده هابدون برچسب عملکرد مدل تقویت می شود. روش پیشنهادی نتایج جدیدی در چهار مجموعه داده بدست آورده است. در حالی که در مجموعه داده های *stl10* مدل تمام نظارتی با در اختیار داشتن ۵۰۰۰ نمونه برچسب دار، دقت ۶۳٫۶ درصدی دارد، مدل پیشنهادی تنها با در اختیار داشتن ۵۰۰۰ نمونه برچسب دار و ۱۰۰۰۰۰ نمونه غیر برچسب دار توانسته است به دقت ۹۴٫۳ درصد برسد. آزمایشات مختلف مقیاس پذیری قدرت تعمیم روش پیشنهادی را چه در راستای افزایش اندازه مجموعه داده های برچسب دار و چه در راستای افزایش اندازه مدل نشان می دهد.

کلیدواژه ها: یادگیری نیمه نظارتی، یادگیری عمیق، دسته بندی، خودآموزی، افزون سازی داده

^۱ دانشگاه صنعتی قم

^۲ Deep learning

^۳ Label

^۴ Semi-supervised learning

^۵ Data Augmentation

^۶ Noisy Students

۱- مقدمه

شبکه های عصبی عمیق در حال حاضر به صورت گسترده در بینایی ماشین و پردازش زبان های طبیعی مورد استفاده قرار میگیرند. موفقیت آنها تقریباً به واسطه مقیاس پذیری آنهاست، به این معنی که هر چه اندازه داده های آموزش بیشتر شود، عملکرد آنها نیز بهبود می یابد. شبکه های عصبی عمیق، برای رسیدن به چنین نتایجی معمولاً نیاز به تعداد زیادی پارامتر دارند که آنها را مستعد بیش برآزش شدن می کند. به همین دلیل، معمولاً نیازمند یک مجموعه داده برچسب دار عظیمی هستند و عملکرد قوی خود را به واسطه یادگیری با نظارت بدست می آورند. اما جمع آوری داده ها برچسب دار برای بسیاری از مسائل هزینه بر است، چون نیاز به دانش یک متخصص دارد که آنها را برچسب بزند. امروزه بواسطه اینترنت در بسیاری از حوزه ها داده های خام بطور انبوه در دسترس می باشد. به طور خلاصه، در بسیاری از مسائل، جمع آوری داده های بدون برچسب به مراتب کار آسان تر و کم هزینه تر است. یکی از راهکارهای موفق برای به کارگیری مجموعه بزرگی از داده های بدون برچسب، استفاده از یادگیری نیمه نظارتی است. از آنجا که داده های بدون برچسب، معمولاً با کمترین نیاز به یک انسان متخصص بدست می آیند، هر بهبودی در عملکرد که از طریق یادگیری نیمه نظارتی حاصل شود، کم هزینه خواهد بود. به همین دلیل، تلاش های بسیاری برای توسعه الگوریتم ها و روشهای نیمه نظارتی صورت گرفته است. در این روش ها، معمولاً تکنیکهایی ارائه می شود که با به کارگیری داده های بدون برچسب از بیش برآزش شدن شبکه جلوگیری می کند. به این ترتیب، تعمیم پذیری مدل افزایش پیدا میکند [1].

آموزش شبکه های عصبی عمیق با استفاده از برچسب های محدود، در سال های اخیر مورد توجه قرار گرفته است. تفاوت روشهای مختلف یادگیری نیمه نظارتی در نحوه به کارگیری داده های بدون برچسب است. برخی از این روشها صرفاً از داده های بدون برچسب برای یادگیری بدون نظارت^۷ استفاده میکنند. [2]. در دسته دیگر، سعی می شود به نحوی برچسب هایی برای نمونه های بدون برچسب تولید شود و از آنها در حین آموزش مدل استفاده کنند [3]. به این برچسب های تولید شده، شبه برچسب^۸ میگویند. این روشها از مشکل تأیید برچسب رنج می برند و پیش بینی اشتباه برای داده های بدون برچسب فرآیند آموزش مدل را دشوارتر می کنند. [4]. اخیراً با تزریق نویز به ورودی مدل بمنظور بالا بردن استحکام^۹ مدل در برابر تغییرات [4] موفقیت خوبی در حوضه یادگیری نیمه نظارتی عمیق بدست آمد. در این مقاله نشان داده شد روش های افزون زایی داده ها چقدر در بالا بردن استحکام مدل نقش مهمی دارند. ایده استحکام مدل با تزریق نویز در الگوریتم نیمه نظارتی خود یادگیری دانشجوی نویز دار [3] نیز بکار گرفته شد.

۱-۱- بیان مسئله

یادگیری نیمه نظارتی خود یادگیر، ترکیبی از یادگیری بانظارت و یادگیری بدون نظارت است. در این حالت، داده ها به دو مجموعه تقسیم می شوند: مجموعه برچسب دار به تعداد محدود (D_l) و مجموعه غیربرچسب دار به تعداد زیاد (D_u). روش های دسته بندی نیمه نظارتی تلاش می کنند، با به کارگیری D_l مدلی بدست آورند که عملکرد آن، در مقایسه با مدلی که تنها بر روی D_l آموزش دیده است، بهتر باشد. یک مشکل اساسی که در الگوریتم های خود یادگیر^{۱۰} بروز میکند خطا در دسته بندی داده های غیر برچسب

⁷ Unsupervised Learning

⁸ Pseudo Label

⁹ Robustness and Consistency

¹⁰ Self-Training

دار می باشد. در الگوریتم دانشجوی نويزدار از مجموعه داده برچسب دار بزرگ استفاده کرده و هدف آن بالا بردن دقت بر روی کل مجموعه بوده است. بعلايه اينکه از کل مجموعه برای آموزش استفاده شده خطای دسته بندی برا برچسب گذاری در حدود ۲٪ بوده است [3] که در مقابل کل مجموعه قابل چشم پوشی است ولی در مجموعه های برچسب دار محدود این خطا در حدود ۴۰٪ میباشد که رقم بزرگی است. اگر این مقدار داده برچسب دار اشتباه وارد مجموعه آموزشی شود قطعاً یادگیری نیمه نظارتی نمی تواند بهبودی در مقایسه با یادگیری نظارتی داشته باشد. حتی ممکن است با گمراه کردن مدل، دقت پیش بینی را نیز کاهش دهد و نتیجه کلی مناسب نخواهد بود.


۲- شیوه انجام تحقیق

۲-۱- نويز

اصلي ترين بخش یادگیری نیمه نظارتی عمیق^{۱۱} تزریق نويز به مدل برای افزایش استحکام مدل است. در این مقاله از ۳ روش برای نويزدار کردن مدل دانشجو استفاده شده است.

۲-۱-۱- Drop Out

واژه‌ی dropout در لغت به معنای بیرون رفتن یا رها کردن است. در هنگام آموزش، برخی از سلول های عصبی^{۱۲} به صورت تصادفی خروجی صفر می گیرند (شکل ۱). این بدین معنا است که آموزش بر روی معماری های مختلف با مجموعه سلول های عصبی متفاوت انجام می گیرد. می توانید به dropout به عنوان یک تکنیک گروهی نگاه کنید که در آن خروجی چندین شبکه مخلوط می شوند تا خروجی نهایی را شکل دهند [5].




شکل ۱ Dropout

¹¹ Deep Semi-Supervised Learning

¹² neuron cell

۲-۱-۲- عمق تصادفی^{۱۳}

عمق تصادفی همانند Dropout در سطح لایه ها عمل میکند. در هر دور آموزش بطور تصادفی تعدادی از لایه ها حذف میشوند (شکل ۲) و بدین وسیله ۲ هدف دنبال میشود. هدف اول کاهش طول شبکه عصبی و در نتیجه کاهش زمان آموزش و هدف دوم جلوگیری از بیش برآزش^{۱۴}. در این مقاله از عمق تصادفی برای بالا بردن استحکام مدل بعنوان تولید کننده نویز در سطح لایه ها استفاده شده است [5].



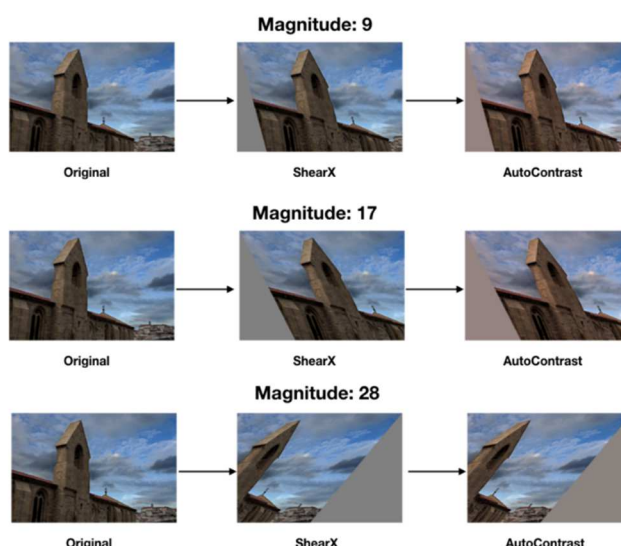
شکل ۲ عمق تصادفی

۲-۱-۳- افزون سازی داده

مهمترین و اصلی ترین روش افزودن نویز به مدل دانشجو در این مقاله افزون سازی داده بصورت شدید است. مدل های دانشجو در زمان آموزش با شدیدترین نوع تغییرات بر روی داده های ورودی مواجه میشوند تا استحکام مدل در بالاترین حد ممکن قرار گیرد. در این مقاله از روش افزون سازی داده RandAugment [7] (شکل ۳) استفاده شده که با کاهش فضای جستجو و ارایه آخرین تکنیک های افزون سازی داده سرعت و کیفیت آموزش را بالاتر برده است.

¹³ Stochastic Depth

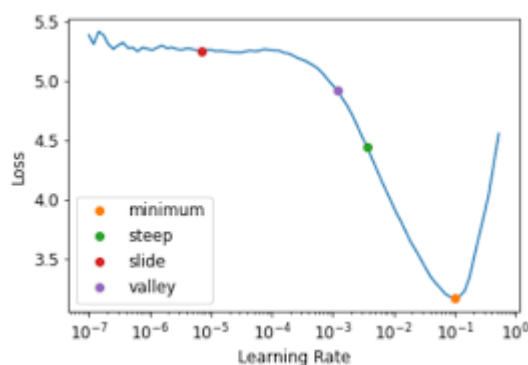
¹⁴ Overfit



شکل ۳ RandAugmentation

۲-۲- پارامترهای بهینه و جلوگیری از بیش برآزش

در روش‌های معمول پیدا کردن نرخ یادگیری که یکی از هایپر پارامترهای مهم در یادگیری می باشد اغلب از کاهش نرخ یادگیری استفاده می شد در این روش غیر از کم کردن گاهی نرخ یادگیری افزایش می دهند به عبارتی نرخ یادگیری افزایشی و کاهشی باشد تا در صورت افتادن در کمینه محلی بتواند از آن خارج شود در واقع کار اصلی آن پیدا کردن نرخ یادگیری مناسب می باشد. اگر نرخ یادگیر را اشتباه بدهیم مدل واگرا شده و به جواب مورد نظر نمی رسد. ابتدا با یک نرخ یادگیری کوچک مدل شروع به یادگیری می کند برای جلوگیری از کند شدن فرآیند یادگیری به جای هر کل داده، بخش کوچکی از داده به مدل داده میشود و بعد از بار آموزش مقدار خطا (Loss) ذخیره و نرخ یادگیری با یک مقدار مشخص شده افزایش پیدا می کند. در نهایت با محاسبه خطای کمینه، نرخ یادگیری متناسب با آن را برمیگرداند (شکل ۴).



شکل ۴ نرخ یادگیری بهینه



از Callback ها برای جلوگیری از بیش برآزش در حین آموزش استفاده شده است. اولین آنها EarlyStopping است که برای تحت نظر گرفتن validation loss است. در صورتی که درحین آموزش مقدار آن کم نشود آموزش را متوقف میکند. دیگری ذخیره بهترین مدل است یعنی ما از اینکه نتیجه آموزش یک مدل با بهترین وزن هاست که این callback این وظیفه را انجام میدهد.

۳- روش دانشجویان نويزدار

۳-۱- آموزش مدل استاد

ابتدا مدل استاد را با استفاده از داده‌های برچسب دار آموزش می‌دهیم و با استفاده از مدل آموزش دیده داده‌های غیربرچسب دار را برچسب گذاری میکنیم.

۳-۲- حذف داده‌های غیرمرتبط

داده‌های غیر برچسب دار ممکن است حاوی سمپل هایی باشند که به هیچ یک از کلاس های ما تعلق نداشته باشند. برای جداسازی آنها از حد^{۱۵} پایین نتیجه پیش بینی مدل استاد استفاده میکنیم. برای اینکار بیشترین مقدار پیش بینی به کلاس ها را با مقدار حد پایین مقایسه میکنیم و در صورتی که کمتر از آن بود حذف شده و در غیر اینصورت به مرحله بعد فرستاده میشود.

۳-۳- متعادل کردن کلاس ها

در اکثر موارد خروجی مرحله قبل یک مجموعه داده غیرمتعادل است. یکی از چالش های یادگیری عمیق چالش مجموعه داده های غیرمتعادل است. در این مقاله از ۲ روش برای متعادل سازی کلاس ها استفاده شده است. در ابتدا تعداد داده های هر کلاس محاسبه شده و بیشترین مقدار داده بعنوان هدف در نظر گرفته میشود. مقادیر مورد نیاز برا هر کلاس با تفاضل ماکزیمم از مقدار هر کلاس محاسبه شده و به دو روش افزایش داده و تولید داده های مصنوعی توسط شبکه های عصبی مولد متخاصم^{۱۶} بصورت مساوی اضافه میشود. باید در نظر داشته باشیم که ورودی هر دو روش داده برچسب دار میباشد نه برچسب خورده ها زیرا هنوز احتمال وجود داده های برچسب خورده اشتباه وجود دارد که با این روش ها مقدار خطا را افزایش خواهیم داد که نتیجه کلی گمراه کننده خواهد بود. روش افزایش داده همان RandAugment میباشد و از Conditional GAN^{۱۷} [8] برای تولید داده های جدید استفاده شده است.

¹⁵ Threshold

¹⁶ Generative Adversarial Network

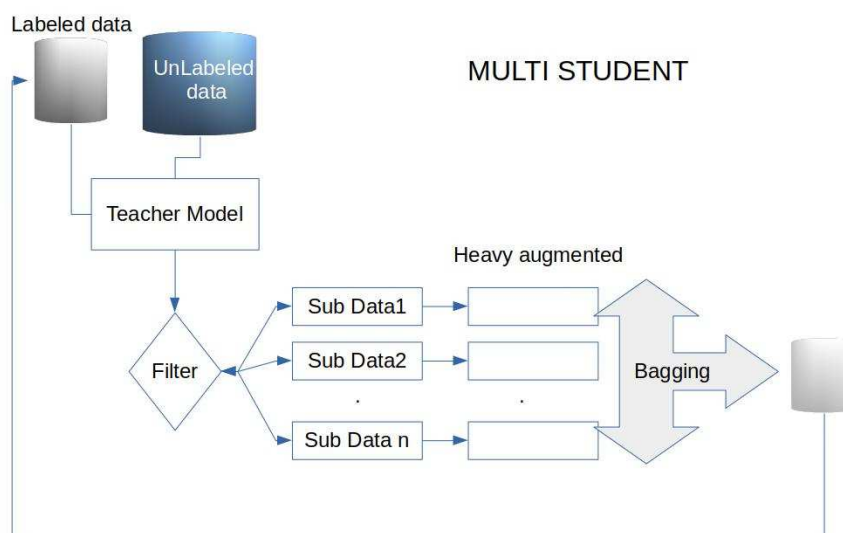
¹⁷ CGAN

۳-۴- تقسیم داده ها

داده های حاصل شده از مرحله قبل به n قسمت تقسیم میشود. از بین آنها $n-1$ بخش را انتخاب کرده و بتوسط آنها $n-1$ دانشجو را آموزش داده میشود. برای آموزش دانشجوها از نویز که در بخش ۲-۱ توضیح داده شد بصورت شدید استفاده میکنیم. یکی از دلایل بهتر عمل نمودن دانشجو ها از استاد بزرگتر بودن مدل و داده های آموزشی دانشجویان حتی ئس از تقسیم داده هاست.

۳-۵- رای گیری

بخش n داده ها که هیچ کدام از دانشجویان با آن آموزش ندیده اند به تمام دانشجویان تزریق میکنیم تا بر روی آن پیش بینی انجام دهند. بر روی $n-1$ پیش بینی رای گیری^{۱۸} کرده و در صورتی که نتیجه رای گیری فقط یک کلاس بود داده را به داده های برچسب دار اضافه کرده و از بین داده ها حذف میکنیم. بخش ۳ را به دفعات تا رسیدن به نتیجه دلخواه تکرار میکنیم که در شکل ۵ شمای کلی آن را میبینیم.



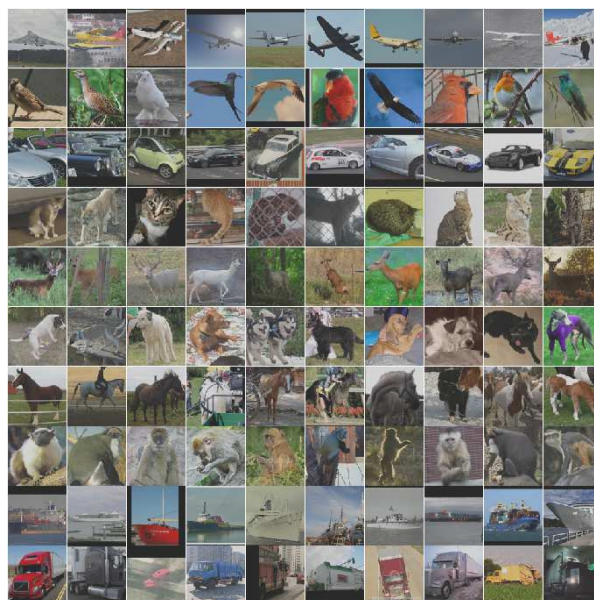
شکل ۵ Multi Student

۴- نتایج

۴-۱- مجموعه داده ها

۴-۱-۱- Stl10

مجموعه داده [9] stl10 از دو بخش برچسب دار و غیر برچسب دار تشکیل شده است که مخصوصا برای آموزش های نیمه نظارتی مورد استفاده قرار میگیرد. تمامی عکس های این مجموعه ۹۶ در ۹۶ پیکسل تشکیل شده و توسط دانشگاه استنفورد جمع آوری شده است. بخش اول دارای ۱۰ کلاس و شامل ۵۰۰ عدد برای هر کلاس بصورت رنگی میباشد. بخش دوم آن شامل ۱۰۰۰۰۰ عکس رنگی غیربرچسب دار است (شکل ۶).



شکل ۶- STL10

۴-۲- CIFAR10

این مجموعه داده شامل ۶۰۰۰۰ عکس به اندازه (۳۲در۳۲) بصورت رنگی در ۱۰ کلاس می باشد. این مجموعه توسط دانشگاه تورنتو تهیه شده است. معمولا برای یادگیری نظارتی مورد استفاده قرار میگیرد ولی در این مقاله به دو بخش ۵۰۰۰ تایی برچسب دار و ۵۵۰۰۰ تا غیر برچسب دار تقسیم شده تا ارزیابی بر روی تعداد خطاهای دسته بندی انجام شود [10].



۵- نتایج آزمایشات

نتایج آزمایشات در جدول ۱ نشان داده شده است.

جدول ۱- خلاصه نتایج آزمایش ها.

Data Set Name	Hyper Parameters	Accuracy on D_I	Final Accuracy
Stl10	batch_size=128, learning_rate=0.001 pooling = max_pooling	63.6	92.2
Stl10	batch_size=64, learning_rate=0.003 pooling = avg_pooling	76.5	94.3
Cifar10	batch_size=128, learning_rate=0.003 pooling = max_pooling	66.6	95.3
Cifar10	batch_size=64, learning_rate=0.001 pooling = avg_pooling	78.4	96.7

۶- نتیجه گیری

روش دانشجویی نویز دار فقط بر روی مجموعه داده های بزرگ آزمایش شده بود در این مقاله هدف ما ارایه روش دانشجویان نویز دار و آزمایش آن بر روی مجموعه داده های کوچک و محدود بود. نتایج حاصله که در جدول ۱ قابل مشاهده است نشان از افزایش تقریباً ۳۰٪ بر روی هر دو مجموعه داده است. با وجود اینکه روش پیشنهادی زمان اجرای طولانی تری نسبت به روشهای یادگیری با نظارت دارد ولی نتایج بدست آمده نشان میدهد که ارزش کار و وقت صرف شده را دارد. بنابر این در حالتی که داده های فراوان در دسترس باشد براحتی میتوان از این روش برای بالا بردن دقت مدل استفاده کرد

مراجع

- [1] A. Oliver, A. Odena, C. Raffel, E. D. Cubuk, and I. J. Goodfellow, "Realistic evaluation of deep semi-supervised learning algorithms," in NeurIPS, 2018, pp. 3239–3250.
- [2] J. T. Springenberg, "Unsupervised and semi-supervised learning with categorical generative adversarial networks," in ICLR, 2016.
- [3] Q. Xie, M. Luong, E. H. Hovy, and Q. V. Le, "Self-training with noisy student improves imagenet classification," in CVPR. IEEE, 2020, pp. 10 684–10 695.
- [4] Q. Xie, Z. Dai, E. H. Hovy, T. Luong, and Q. Le, "Unsupervised data augmentation for consistency training," in NeurIPS, 2020.
- [5] S. Park, J. Park, S. Shin, and I. Moon, "Adversarial dropout for supervised and semi-supervised learning," in AAAI. AAAI Press, 2018, pp. 3917–3924



پنجمین کنفرانس ملی کامپیوتر، فناوری اطلاعات و
کاربردهای هوش مصنوعی
۱۵ اسفندماه ۱۴۰۰



- [6] G. Huang, Y. Sun, Z. Liu, D. Sedra, and K. Weinberger, "Deep Networks with Stochastic Depth," *arXiv:1603.09382 [cs]*, Jul. 2016, Accessed: Feb. 11, 2022. [Online]. Available: <http://arxiv.org/abs/1603.09382>
- [7] E. D. Cubuk, B. Zoph, J. Shlens, and Q. V. Le, "RandAugment: Practical automated data augmentation with a reduced search space," *ArXiv190913719 Cs*, Nov. 2019, Accessed: Feb. 11, 2022. [Online]. Available: <http://arxiv.org/abs/1909.13719>
- [8] M. Mirza and S. Osindero, "Conditional Generative Adversarial Nets," *ArXiv14111784 Cs Stat*, Nov. 2014, Accessed: Feb. 11, 2022. [Online]. Available: <http://arxiv.org/abs/1411.1784>
- [9] "STL-10 dataset." <https://cs.stanford.edu/~acoates/stl10/> (accessed Feb. 11, 2022).
- [10] "CIFAR-10 and CIFAR-100 datasets." <https://www.cs.toronto.edu/~kriz/cifar.html> (accessed Feb. 11, 2022).