

مقایسه انواع روش‌های پیش‌بینی میزان مصرف آب شرب شهری (مطالعه موردی: شهرک مهدیه قم)

مصطفی رضا علی^۱، عبدالرضا کریمی^{۲*}، بایرامعلی محمدنژاد^۳، عبدالرضا رسولی کناری^۴

۱- دانشجوی کارشناسی ارشد عمران محیط زیست دانشگاه صنعتی قم ، rezaali.m@qut.ac.ir

۲- استادیار گروه مهندسی عمران، دانشگاه صنعتی قم، karimi@qut.ac.ir

۳- استادیار گروه مهندسی عمران، دانشگاه صنعتی قم، mohammadnezhad@qut.ac.ir

۴- استادیار گروه مهندسی کامپیوتر، دانشگاه صنعتی قم، rasouli@qut.ac.ir

چکیده

در سال‌های اخیر خشک‌سالی‌های پی‌درپی، باعث کاهش میزان منابع آبی کشور شده است. تنش‌های ناشی از این خشک‌سالی‌ها بیشتر در شهرها و کلان‌شهرهای با اقلیم خشک و نیمه‌خشک مشهود است که توأم با افزایش جمعیت شهری، این تنش‌ها روبه افزایش است. در دهه‌های اخیر، پژوهشگران به منظور مدیریت بهتر میزان تقاضا و ایجاد توازن میان عرضه و تقاضا، به روش‌های پیش‌بینی میزان تقاضای آب شهری روی آورده‌اند که استفاده از آنها می‌تواند به مدیریت عرضه و تقاضا کمک شایانی کند. یکی از روش‌های مرسوم برای این کار استفاده از مدل‌های آماری است که مدل میانگین متحرک خودهمبسته یکپارچه یا ARIMA یکی از شناخته‌شده‌ترین آنها در بین پژوهشگران این حوزه است. باگذشت زمان و دستیابی به تعریف کاربردی از هوش مصنوعی، روش‌های مبتنی بر هوش مصنوعی به‌جامعه علمی جهان معرفی شد که روش شبکه عصبی مصنوعی یکی از پرکاربردترین آنها است. بعد از اولین استفاده کاربردی از شبکه عصبی مصنوعی، مقایسه بین این روش با ARIMA موردتوجه بسیاری از پژوهشگران قرار گرفت. در این پژوهش نیز سعی شده با استفاده از این روش و مقایسه کلی آنها، میزان دقت آنها در پیش‌بینی تقاضای آب شهرک مهدیه شهر قم مشخص شود. نتایج این پژوهش نشان داد که مدل شبکه عصبی مصنوعی سری‌زمانی قابلیت بهتری در زمینه پیش‌بینی تقاضای آب دارد. مدل ARIMA نیز توانایی مطلوبی در این زمینه نشان داد. باتوجه به ساده‌تر بودن مدل ARIMA، دانش کمتر برای به‌کارگیری آن، دسترسی آسان‌تر به آن و هزینه محاسباتی کمتر ممکن است بعضاً انتخاب مناسبی برای تصمیم‌گیران این حوزه به‌شمار می‌رود.

واژه‌های کلیدی: پیش‌بینی تقاضا، شبکه عصبی مصنوعی، مدل میانگین متحرک خود همبسته یکپارچه، مدل‌های سری‌زمانی

۱- مقدمه

آب به‌عنوان یکی از مهم‌ترین نیازهای بشر، در زندگی هر انسانی دارای نقش حیاتی است. آگاهی از میزان مصرف آب برای سیاست‌گذاری مدیریت تقاضا و کنترل فشار در شبکه، از اهمیت ویژه‌ای برخوردار است. یکی از مهم‌ترین دغدغه‌های جوامع مدرن، پیش‌بینی میزان مصرف آب در آینده دور یا نزدیک است. از این‌رو روش‌های گوناگون آماری مانند برازش کردن مدل به آن و بعدتر استفاده از هوش مصنوعی برای این مهم بکار گرفته شده است. پیش‌بینی میزان مصرف آب شهری با دلایل مختلفی اعم از مدیریت بهینه مصرف آب، کاهش تلفات آب و کاهش اثرات ناشی از افزایش بی‌رویه فشار در شبکه صورت می‌گیرد (Adamowski et al., 2012). امروزه قطعی‌های مکرر در شبکه آب شهری استان‌های خشک و نیمه‌خشک باعث تحمیل خسارات زیادی بر مشترکان شده است. یکی از راه‌هایی که می‌تواند به برون‌رفت از این بحران کمک کند، پیش‌بینی میزان مصرف آب مشترکان چه در کوتاه‌مدت و چه در بلندمدت است. اما با توجه به اینکه تاکنون روش‌های مختلفی برای مدل‌سازی رفتار مشترکان وجود دارد، جواب به این سؤال که در این زمینه کدام یک از روش‌ها می‌تواند بهتر عمل کند همچنان مورد بحث جوامع علمی است (Donkor et al., 2012).

بطور کلی پیش‌بینی مصرف آب را می‌توان به سه دسته کلی کوتاه‌مدت، میان‌مدت و بلندمدت تقسیم کرد. در پیش‌بینی کوتاه‌مدت میزان مصرف تقریبی آب در ساعات و روزهای آینده تخمین زده می‌شود، درحالی‌که در پیش‌بینی میان‌مدت و بلندمدت، هدف تخمین میزان مصرف آب به ترتیب در ماه‌ها یا فصول آینده و در سال بعدی است. از مهم‌ترین مراحل مدل‌سازی و درنهایت پیش‌بینی میزان مصرف آب شهری، یافتن پارامترهای تأثیرگذار بر آن است. بطور کلی، در شهر مصارف چهارگانه عمومی، خانگی، تجاری و صنعتی برای آب وجود دارد. الگوی مصرف در هرکدام از انواع مصارف ذکر شده می‌تواند با توجه به شرایط مختلف متفاوت باشد. به‌عنوان مثال، ثابت شده در مصارف شهری میزان مصرف تابع برخی پارامترهای جوی است (Adamowski and Karapataki, 2010). با توجه به پژوهش‌های انجام شده، مهم‌ترین پارامترهای تأثیرگذار بر میزان مصرف آب شهری به دو دسته کلی تقسیم‌بندی می‌شود که عبارت‌اند از پارامترهای جوی شامل بیشینه دما، میزان بارندگی، وقوع با عدم وقوع بارش و سرعت باد و پارامتر میزان آب مصرفی در دوره زمانی قبل شامل روز قبل، هفته قبل و سال قبل است (Baumann et al., 1998). در این پژوهش سعی شده با معرفی شناخته‌شده‌ترین مدل‌های سری‌زمانی در این زمینه یعنی مدل‌های آماری و مدل‌های مبتنی بر هوش مصنوعی، عملکرد آنها در پیش‌بینی میزان آب شهری در قالب مطالعه موردی باهم مقایسه گردد.

۲- منطقه مورد مطالعه

استان قم با مساحت ۱۱۲۳۸ کیلومترمربع و اقلیم خشک و نیمه‌خشک از دسته استان‌های در معرض تنش آبی محسوب می‌شود. مهم‌ترین منبع تأمین آب شرب شهر از طریق طرح انتقال آب از سرشاخه‌های دز و درنهایت سد کوچری واقع در شهرستان گلپایگان در شمال غرب استان اصفهان می‌باشد. آب انتقالی پس از تصفیه در تصفیه‌خانه آب دودک، به مخازن ذخیره شهری و سپس به شبکه آب شهری منتقل می‌شود. در این پژوهش با توجه به تداوم اندازه‌گیری و پایگاه غنی‌تر داده‌های مصرف آب، شهرک مهدیه قم، به عنوان محدوده مورد مطالعه انتخاب گردید.

۳- مواد و روش‌ها

داده‌های سری‌زمانی میزان مصرف آب شرب مخزن مهدیه که هر ۱۵ دقیقه یک‌بار به مدت ۲۸۳ روز به ثبت رسیده از سازمان آب و فاضلاب شهر قم دریافت شد. بمنظور محاسبه دقیق میزان مصرف آب، از داده‌های ۱۵ دقیقه‌ای به‌صورت روزانه انتگرال گرفته شد. این روش نسبت به روش میانگین روزانه از دقت بالاتری برخوردار است. به دلیل بالا بودن تعداد روزها، در محیط MATLAB برنامه‌ای نوشته شد تا این عملیات را به‌صورت خودکار برای هرروز انجام دهد. داده‌های مذکور به همراه داده‌های جوی شامل حداکثر دمای روزانه، سرعت باد، میزان بارندگی، وقوع یا عدم وقوع بارندگی و تعطیلات و مناسبت‌های تقویم، تحت آنالیز Spearman-correlation قرار گرفت، تا مشخص شود کدام‌یک از داده‌ها سطح معناداری بیشتری نسبت به سایر پارامترها دارند. نتایج نشان داد که پارامترهای میزان بارندگی، وقوع یا عدم وقوع بارندگی و مناسبت‌ها به ترتیب دارای کمترین میزان معناداری هستند. درنتیجه از این پارامترها به‌عنوان ورودی مدل‌ها استفاده نشد. در مرحله بعد به منظور شناخت بهترین تأخیرها برای اعمال روی داده‌های سری‌زمانی، آنالیز Cross-Correlation بر روی داده‌ها انجام شد. درنهایت از نتایج این آنالیز به منظور اعمال تأخیرها بر روی مدل‌های سری‌زمانی استفاده شد.

برای مدل سازی سری زمانی با استفاده از مدل های آماری، مدل^۱ ARIMA که در پژوهش های مختلف مورد استفاده قرار می گیرد، انتخاب شد. این مدل توانایی شناسایی الگوهای پیچیده سری زمانی و قابلیت پیش بینی برای این دسته از داده ها (Baumann et al., 1998) را دارد. مدل سری زمانی ARIMA بر اساس معادله ۱ نسبت به فیت کردن اقدام می کند (Box and Jenkins, 1976).

$$ARIMA(p, d, q) = \varphi_p(B)(B-1)^d Y_t = \delta + \theta_q(B)\varepsilon_t \quad (1)$$

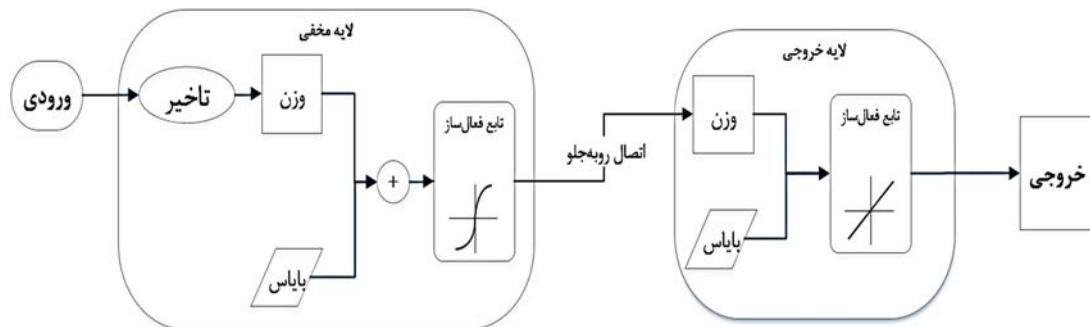
که در آن Y مقدار اصلی سری مان، ε_t نویز سفید، B اپراتور بکشیفت، δ مقدار ثابت، φ_p پارامتر خودانباشته از درجه p ، θ_q میانگین متحرک از درجه q و d درجه تفاضل هستند.

این شبکه ها با الهام گرفتن از ساختار بدن و با هدف تقلید از هوش انسان معرفی شده اند. شبکه عصبی مصنوعی، شبکه ای بر پایه الگوریتم های ریاضی با قابلیت حل و مدل سازی انواع سیستم های دینامیکی با روابط غیرخطی است. بطور کلی شبکه عصبی مصنوعی را می توان مجموعه ای از نورون ها دانست که با یکدیگر در ارتباط هستند (Govindaraju and Rao, 2013). از جمله کاربردهای این روش می توان در حل مسائل کنترلی، پردازش سیگنال، شناسایی الگو، تقریب توابع، پیش بینی و انتخاب محصول نام برد (Basseville, 1989, Li et al., 2018, Park et al., 1991, Samal and Iyengar, 1992, Yang and Huang, 1994). این روش اخیراً توجه بسیاری از محققان حوزه آب را جلب کرده است. از مهم ترین کاربردهای این روش می توان به پیش بینی میزان جریان آب رودخانه ها، میزان بارندگی، تخمین میزان رواناب سطحی، برآورد جریان های زیرسطحی و کنترل کیفیت آب اشاره کرد (Singh et al., 2009, Schaap et al., 1998, Hsu et al., 1995, Cannas et al., 2006).

ساختار پرسپترون چندلایه یکی از پرکاربردترین این روش ها است. در این ساختار نورون ها در لایه های مختلف قرار گرفته که در نهایت ساختار چندلایه را می سازد. این ساختار حداقل دارای ۳ لایه است. لایه اول لایه ورودی، لایه دوم لایه پنهان و لایه سوم لایه خروجی نام دارد. معادله ریاضی حاکم بر یک شبکه پرسپترون چندلایه پیشخور^۲ به شرح معادله ۲ است (Adamowski et al., 2012, FŞ and Fidan, 2009).

$$O_k = g_2 \left[\sum_j V_j w_{kj} g_1 \left(\sum_i w_{ji} I_i + w_{j0} \right) + w_{k0} \right] \quad (2)$$


که در آن I_i میزان ورودی به مدل در گره i ام، V_j کمیت پنهان در لایه پنهان، O_k خروجی لایه نهایی مدل، w_{ji} ، w_{kj} به ترتیب معرف وزن گره در لایه مخفی j و لایه خروجی k و وزن گره در لایه ورودی i ام و گره مخفی j ام است. w_{j0} و w_{k0} به ترتیب معرف وزن بایاس در لایه ورودی $I_0 = 0$ و وزن بایاس در لایه خروجی $V_0 = 1$ است. g_1 و g_2 هم به ترتیب توابع فعال سازی لایه های پنهان و خروجی است. لازم به ذکر است شبکه عصبی مصنوعی بکار رفته در این پژوهش از نوع شبکه عصبی مصنوعی دینامیکی یا سری زمانی است که با اعمال تأخیرهای مختلف بر روی داده های ورودی عمل می کند. الگوریتم بهینه سازی مدل از نوع لونبرگ مارکوارت انتخاب شد. وظیفه این الگوریتم که نسخه اصلاح شده الگوریتم کلاسیک نیوتن هست (Hornik et al., 1989)، پیدا کردن حداقل مقدار موجود در تابع هزینه مدل است. این الگوریتم نسب به بقیه روش های بهینه سازی مدل، دارای سرعت و کارایی بیشتری است. شکل ۱ نمونه ای از یک شبکه عصبی مصنوعی پرسپترون چندلایه با اتصال پیشخور را نشان می دهد. لازم به ذکر است که نوع تابع فعال ساز این مدل با توجه به پژوهش های گذشته در زمینه پیش بینی تقاضای آب (Adamowski et al., 2012, Baumann et al., 1998, Donkor et al., 2012, Flood and Kartam, 1994, Herrera et al., 2010, Maier and Dandy, 2000, Singh et al., 2009) و تست انواع توابع فعال ساز دیگر، برای لایه مخفی، تابع Tansig و برای لایه خروجی تابع خطی استفاده شد.



شکل ۱: شمای کلی شبکه عصبی مصنوعی پرسپترون چندلایه بکار رفته در پژوهش

۴- نتایج و بحث


با توجه به اهمیت پیش بینی تقاضای آبی شبکه توزیع شهری در تنظیم فشار شبکه، تامین آب، کاهش خسارات تاسیسات انتقال آب و تلفات آبی، این موضوع از طریق دو مدل ARIMA و شبکه عصبی مصنوعی مورد بررسی قرار گرفت. بررسی نتایج نشان داد قبل از استفاده از ARIMA لازم است تا ماهیت ایستایی داده‌ها مشخص شود. بدین منظور، با استفاده از تست‌های دیکی-فولر، فیلیپس-پرون و KPSS مشخص شد که هر سه تست تأکید بر ماهیت غیرایستا بودن داده‌ها دارد. داده‌های میزان نیاز آبی معمولاً غیرایستا هستند که برای ایستا کردن این داده‌ها از عملیات تفاضلی درجه ۱ یا بالاتر در مدل ARIMA استفاده می‌شود. قبل از به کارگیری مدل، داده‌ها ابتدا طی عملیات تفاضلی تغییر حالت داده شد^۳ تا از ایستا بودن آنها اطمینان حاصل شود. شکل ۲ مقایسه میزان پیش‌بینی شده با میزان واقعی را نشان می‌دهد. بهترین پارامترهای مدل با استفاده از روش آزمون و خطا به صورت $ARIMA(3, 1, 2)$ انتخاب شد. روش انتخاب بر پایه حداقل میزان خطای پیش‌بینی مدل‌ها با تغییر هر کدام از این پارامترها است. به طور مشابه، مدل سری زمانی نیز تحت آموزش قرار گرفت.



شکل ۲: مقایسه میزان برآورد شده مدل ARIMA با میزان اندازه‌گیری شده نیاز آبی شهرک مهدیه در طول دوره مدل‌سازی

همان طور که در شکل ۲ مشخص است، مدل توانایی قابل قبولی از خود نشان می‌دهد. توانایی مدل در زمینه پیش‌بینی میزان حداقل‌ها و حداکثرهای مکانی و مقادیر غیرمنتظره مشهود است. بعضاً می‌توان به صورت بصری تأخیر پیش‌بینی را در خروجی مدل مشاهده کرد که رفته‌رفته کم‌تر می‌شود، اما بطور کلی عملکرد مدل مطابق شکل ۲ را می‌توان مطلوب برآورد کرد.

به طور مشابه، مدل شبکه عصبی مصنوعی سری‌زمانی نیز تحت آموزش قرار گرفت. بهترین مدل با یک لایه مخفی^۴، ۲ نورون و تأخیرهای ۱ تا ۷ روزه به عنوان مدل بهینه انتخاب شد. شکل ۳ میزان مقادیر واقعی در مقایسه با میزان محاسبه شده توسط مدل را نشان می‌دهد. داده‌ها به صورت ۷۰، ۱۵ و ۱۵ به ترتیب برای آموزش^۵، اعتبارسنجی^۶ و تست مورد استفاده قرار گرفت. همچنین به علت وابستگی‌های زمانی^۷ که ممکن است در اثر تصادفی کردن ترتیب داده‌های ورودی حین فرآیند آموزش به وجود آید (Duerr et al., 2018, Herrera et al., 2010)، ترتیب استفاده از داده به صورت بلوکی^۸ انتخاب شد.



شکل ۳: مقایسه میزان برآورد شده مدل شبکه عصبی مصنوعی سری‌زمانی با میزان اندازه‌گیری شده نیاز آبی شهرک مهدیه در طول دوره مدل‌سازی

همان طور که در شکل ۳ مشخص است، از لحاظ بصری مدل توانسته سری‌زمانی را در حالت آموزش بطور مطلوبی تخمین بزند. توانایی مدل در پیش‌بینی حداقل‌ها و حداکثرهای سری‌زمانی قابل توجه است. نسبت به مدل ARIMA، در مدل شبکه عصبی مصنوعی سری‌زمانی، تأخیرها بسیار ناچیزتر است. دلیل این امر را می‌توان در الگوریتم یادگیری بکار گرفته شده، بیش‌برازش^۹ مدل به دلیل تعداد نورون و لایه‌های بیش‌ازحد و نوع توابع فعال‌سازی در لایه خروجی و لایه مخفی مدل جویا شد.

لازم به ذکر است که بهترین مدل بر اساس نوع همگرایی^{۱۰} خطاهای آموزش، اعتبارسنجی و تست و میزان آنها برحسب میانگین مجذور خطا انتخاب شد. در جدول ۱ مقایسه خطای آموزش محاسبه شده دو مدل شبکه عصبی مصنوعی سری‌زمانی با ARIMA مشخص شده است.

جدول ۱: مقایسه خطای مدل‌های سری‌زمانی ARIMA و شبکه عصبی مصنوعی سری‌زمانی

شبکه عصبی مصنوعی سری‌زمانی	ARIMA	پارامترهای مقایسه عملکرد مدل‌ها
۳۰۳۵۵۰۸۵	۳۳۲۷۰۶۱۹	SSE
۱۱۰۷۸۵	۱۱۹۲۴۹	MSE
۳۳۲	۳۴۵	RMSE (m ³)
۲۲۹	۲۳۹	(m ³) میانگین خطا
۳۳۰	۳۴۵	(m ³) انحراف معیار
۰/۴	۰/۵	(m ³) حداقل خطا
۱۵۶۲	۱۷۱۲۰	(m ³) حداکثر خطا

با توجه به جدول ۱ و در نظر گرفتن رفتار مدل‌ها در رابطه با پیش‌بینی تقاضای آب شهری، می‌توان نتیجه گرفت که مدل شبکه عصبی مصنوعی توانایی بهتری نسب به مدل ARIMA در این پژوهش دارد. مدل شبکه عصبی مصنوعی از همه لحاظ دارای برتری نسبی است که دلیل این برتری را می‌توان در پیچیدگی‌های بیشتر این مدل که منجر به تولید پارامترهای بیشتر برای تنظیم بهتر مدل نسبت به ARIMA می‌گردد، دانست. از طرفی، نمی‌توان سادگی نسبی مدل ARIMA، قابلیت به‌کارگیری بهتر آن و دسترسی آسان‌تر به این مدل را نادیده گرفت. هرچند عملکرد این مدل بهتر از مدل شبکه عصبی مصنوعی نبود، اما نباید فراموش کرد این مدل در نوع خود و در مقایسه با شبکه عصبی مصنوعی عملکرد قابل قبول و حتی فراتر از انتظار از خود نشان داد.

۵- نتیجه‌گیری

پیش‌بینی نیاز آب شهری یکی از ملزومات کنترل و مدیریت عرضه و تقاضا در شبکه توزیع آب شهری است. بدین منظور مدل‌های مبتنی بر روش‌های آماری و اخیراً مدل‌های مبتنی بر هوش مصنوعی تحت پژوهش‌های گسترده قرار گرفته است. در این پژوهش دو نوع از پرکاربردترین مدل‌ها که عبارت‌اند از مدل ARIMA و مدل شبکه عصبی مصنوعی سری‌زمانی در زمینه پیش‌بینی تقاضا در شبکه آب شهری تحت بررسی قرار گرفت تا مشخص شود کدام یک عملکرد بهتری از نظر میزان خطای پیش‌بینی دارند.

مقایسه نتایج نمودارهای خروجی مدل ARIMA و مدل شبکه عصبی مصنوعی سری‌زمانی، نشان داد که مدل شبکه عصبی مصنوعی سری‌زمانی، قابلیت بهتری در زمینه پیش‌بینی میزان حداقل‌ها، حداکثرها و تغییرات غیرمنتظره در میزان تقاضای آب نسبت به مدل ARIMA دارد. همچنین نتایج محاسبه خطای هر دو مدل دلالت بر برتری نسبی مدل شبکه عصبی مصنوعی سری‌زمانی داشت. از طرفی مدل ARIMA هرچند که خطای نسبتاً بیشتری در مقایسه با مدل دیگر داشت، اما مزیت‌های دیگر این مدل و خطای قابل چشم‌پوشی آن در مقایسه با شبکه عصبی مصنوعی باعث می‌شود این مدل رقیب ساده‌ای برای مدل شبکه عصبی مصنوعی نباشد. همچنین می‌توان این‌طور نتیجه گرفت که مدل شبکه عصبی مصنوعی دارای پارامترهای بسیار بیشتری برای تنظیم در مقایسه با مدل ARIMA هست که این مسئله خود باعث می‌شود تا مدل آموزش دیده را بهینه‌ترین (از لحاظ خطای محاسباتی) مدل ممکن برای مقایسه با مدل ARIMA ندانست. چراکه اساساً رسیدن به بهینه‌ترین مدل ممکن نیازمند صرف هزینه‌های محاسباتی و زمانی بسیار است.

۶- قدردانی

نویسندگان مقاله از شرکت آب و فاضلاب شهری استان قم و سازمان هواشناسی کشوری بمنظور مساعدت در دریافت داده‌ها تشکر می‌نمایند.

۷- پی‌نوشت‌ها

1. Autoregressive Integrated Moving Average
2. Feedforward
3. Differencing Transformation
4. Hidden Layer
5. Training
6. Validation
7. Temporal Dependencies
8. Divide Block
9. Overfitting
10. Convergence

۸- منابع

- ADAMOWSKI, J., FUNG CHAN, H., PRASHER, S. O., OZGA-ZIELINSKI, B. & SLIUSARIEVA, A. 2012. Comparison of multiple linear and nonlinear regression, autoregressive integrated moving average, artificial neural network, and wavelet artificial neural network methods for urban water demand forecasting in Montreal, Canada. *Water Resources Research*, 48.
- ADAMOWSKI, J. & KARAPATAKI, C. 2010. Comparison of multivariate regression and artificial neural networks for peak urban water-demand forecasting: evaluation of different ANN learning algorithms. *Journal of Hydrologic Engineering*, 15, 729-743.
- BASSEVILLE, M. 1989. Distance measures for signal processing and pattern recognition. *Signal processing*, 18, 349-369.
- BAUMANN, D. D., BOLAND, J. & HANEMANN, W. M. 1998. *Urban water demand management and planning*, McGraw-Hill New York.
- BOX, G. E. & JENKINS, G. M. 1976. *Time Series Analysis: forecasting and control*, rev. edn. *Holder-Day, San Francisco, CA, USA*.
- CANNAS, B., FANNI, A., SEE, L. & SIAS, G. 2006. Data preprocessing for river flow forecasting using neural networks: wavelet transforms and data partitioning. *Physics and Chemistry of the Earth, Parts A/B/C*, 31, 1164-1171.
- DONKOR, E. A., MAZZUCHI, T. A., SOYER, R. & ALAN ROBERSON, J. 2012. Urban water demand forecasting :review of methods and models. *Journal of Water Resources Planning and Management*, 140, 146-159.
- DUERR, I., MERRILL, H. R., WANG, C., BAI, R., BOYER, M., DUKES, M. D. & BLIZNYUK, N. 2018. Forecasting urban household water demand with statistical and machine learning methods using large space-time data: A Comparative study. *Environmental Modelling & Software*, 102, 29-38.
- FLOOD, I. & KARTAM, N. 1994. Neural networks in civil engineering. I: Principles and understanding. *Journal of computing in civil engineering*, 8, 131-148.
- FŞ, Ö. & FIDAN, H. 2009. Estimation of pesticides usage in the agricultural sector in Turkey using artificial neural network (ANN). *Journal of Animal & Plant Sciences*, 4, 373-378.
- GOVINDARAJU, R. S. & RAO, A. R. 2013. *Artificial neural networks in hydrology*, Springer Science & Business Media.
- HERRERA, M., TORGO, L., IZQUIERDO, J. & PÉREZ-GARCÍA, R. 2010. Predictive models for forecasting hourly urban water demand. *Journal of hydrology*, 387, 141-150.
- HORNIK, K., STINCHCOMBE, M. & WHITE, H. ۱۹۸۹. Multilayer feedforward networks are universal

- approximators. *Neural networks*, 2, 359-366.
- HSU, K. L., GUPTA, H. V. & SOROOSHIAN, S. 1995. Artificial neural network modeling of the rainfall-runoff process. *Water resources research*, 31, 2517-2530.
- LI, Y., WANG, G., NIE, L., WANG, Q. & TAN, W. 2018. Distance metric optimization driven convolutional neural network for age invariant face recognition. *Pattern Recognition*, 75, 51-62.
- MAIER, H. R. & DANDY, G. C. 2000. Neural networks for the prediction and forecasting of water resources variables: a review of modelling issues and applications. *Environmental modelling & software*, 15, 101-124.
- PARK, D. C., EL-SHARKAWI, M., MARKS, R., ATLAS, L. & DAMBORG, M. 1991. Electric load forecasting using an artificial neural network. *IEEE transactions on Power Systems*, 6, 442-449.
- SAMAL, A. & IYENGAR, P. A. 1992. Automatic recognition and analysis of human faces and facial expressions: A survey. *Pattern recognition*, 25, 65-77.
- SCHAAP, M. G., LEIJ, F. J. & VAN GENUCHTEN, M. T. 1998. Neural network analysis for hierarchical prediction of soil hydraulic properties. *Soil Science Society of America Journal*, 62, 847-855.
- SINGH, K. P., BASANT, A., MALIK, A. & JAIN, G. 2009. Artificial neural network modeling of the river water quality—a case study. *Ecological Modelling*, 220, 888-895.
- YANG, G. & HUANG, T. S. 1994. Human face detection in a complex background. *Pattern recognition*, 27, 53-63.

Comparison of Methods for Urban Water Demand Prediction, Case Study: Mahdie Residential Complex, Qom

**Mostafa Rezaali¹, Abdolreza Karimi^{*2}, Bayramali Mohammadnezhad³,
Abdolreza Rasouli Kenari⁴**

1. M.Sc. Student of Civil and Environmental Engineering, Qom University of Technology, Rezaali.m@qut.ac.ir

2. Assistant Professor, Department of Civil Engineering, Qom University of Technology, Karimi@qut.ac.ir

3. Assistant Professor, Department of Civil Engineering, Qom University of Technology, Mohammadnezhad@qut.ac.ir

4. Assistant Professor, Department of Computer Engineering, Qom University of Technology, Rasouli@qut.ac.ir

Abstract

The recent consecutive droughts caused a decrease in the water supplies of the country. The tensions raised from the droughts, which are increasing by the population growth, are more sensible in cities and megacities with arid and semi-arid climates. In the recent decades, researchers with the aim to manage demand and supply better and balancing them, studied the methods to predict urban water demand which using them may lead to better manage the demand and supply. One of the common methods in this field is using statistical models which autoregressive integrated moving average is one the most known among the researchers in this field. By course of time and achieving an applicable definition of artificial neural networks (ANN), the methods based on ANN were introduced to the scientific community; ANN is now one of the most adopted methods. After the first application of ANN, comparing this method with ARIMA attracted the attention of many researchers. In this research, an effort is made to study the ANN and compare it with ARIMA, measure their accuracy in predicting the water demand of Mahdiah Residential Complex, Qom. The results of this study showed dynamic ANN has a better ability to predict the water demand. However, ARIMA also had an acceptable performance in this study. Therefore, considering the simplicity of this model, lower prior understanding of the model, better accessibility and lower computational costs can be an optimal choice for decision makers in this field.

Keywords: Demand Prediction, Artificial Neural Network, ARIMA, Time Series Models, Autoregressive Integrated Moving Average