



## مروری بر تشخیص عملکرد کاربران و ارائه ی روش جدیدی برای شناسایی فعالیت کاربران در خانه ی هوشمند

حانیه عباسی<sup>۱</sup>، محبوبه شمسی<sup>۲</sup>، عبدالرضا رسولی کناری<sup>۳</sup>

<sup>۱</sup>دانشگاه صنعتی قم، h.abasi1372@gmail.com

<sup>۲</sup>دانشگاه صنعتی قم، shamsi@qut.ac.ir

<sup>۳</sup>دانشگاه صنعتی قم، rasouli@qut.ac.ir

### چکیده

در سالهای اخیر، جمعیت افراد بیمار و سالمند که به تنهایی در خانه زندگی می کنند و نیاز به مراقبت دارند، افزایش یافته است. همین مسئله احتیاج به داشتن خانه ی هوشمند برای باخبر بودن از شرایط بیمار را افزایش می دهد. شناسایی فعالیت بیمار با استفاده از حسگرهای تعبیه شده در محیط، اولین قدم برای رسیدن به خانه ی هوشمندی است که در آن اطرافیان بیمار می توانند با نگرانی کمتری، بیمار را در خانه تنها بگذارند. الگوریتمی که برای شناسایی فعالیت بیمار انتخاب می شود، باید کمترین مقدار خطا را داشته باشد. در این پژوهش مروری بر انواع روش های تشخیص عملکرد کاربران در خانه ی هوشمند صورت می گیرد و پس از آن، از یکی از الگوریتم های سری زمانی (الگوریتم شبکه عصبی مبتنی بر سری زمانی) برای شناسایی فعالیت بیمار استفاده شده است که دقت بالایی را در شناسایی نشان می دهد.

**واژگان کلیدی:** خانه ی هوشمند، شناسایی فعالیت، افراد مسن، الگوریتم سری زمانی

### مقدمه

در سالهای اخیر، جمعیت افراد سالمند روز به روز در حال افزایش است. طبق آمار سازمان بهداشت جهانی (WHO)، جمعیت افراد بالای ۶۵ سال بین سالهای ۲۰۱۵ تا ۲۰۵۰ از ۹۰۰ میلیون به دو میلیارد خواهد رسید که این به معنای رسیدن به ۲۲ درصد سالمند در سال ۲۰۵۰ می باشد (WHO, 2017). زوال عقل، اولین علت وابستگی و نیازمندی در سالمندان تلقی می شود و افراد کافی برای مراقبت از این قشر پرجمعیت وجود ندارد. با توجه به افزایش تعداد سالمندان نسبت به کل افراد، بروز این بیماری بیشتر شده و مسئله ی مراقبت از آنها نیز، اهمیت بیشتری پیدا کرده است (Association, 2012; Organization, 2015).

طراحی یک خانه ی هوشمند می تواند در کمک رسانی به این افراد بسیار موثر باشد. خانه ی هوشمند رفتار کاربر را با استفاده از حسگرهای تعبیه شده در محیط، مورد بررسی قرار داده و نقش یک مراقب را ایفا می کند و تنها در صورت احساس بروز مشکل، آن را به یکی از وابستگان بیمار- برای بررسی بیشتر- اطلاع می دهد. یکی از مشکلاتی که می تواند برای یک سالمند به وجود بیاید، سقوط وی است. پدیده ی افتادن، معمولاً با عوارض و ناتوانی های جسمی و حتی مرگ همراه است؛ به طوری که طبق گزارشی، مرگ در افراد بالای ۶۵ سال، از سال ۲۰۰۷ تا ۲۰۱۶ به میزان ۳۱ درصد افزایش یافته است (Allen, 2018; Shakeri, 2017). مشکل دیگر می تواند اختلالات بیمار و درست انجام ندادن کارهای معمول روزانه از قبیل رعایت نشدن زمان شروع فعالیت و انجام آن در یک بازه زمانی نامتعارف و یا طولانی شدن آن فعالیت باشد (K. S. Gayathri, 2015; K.S.Gayathri, 2016). در این مقاله ابتدا مروری بر انواع روش های تشخیص عملکرد

کاربران در خانه ی هوشمند بیان می شود و در نهایت، با استفاده از یک روش جدید، نوع فعالیت کاربر با استفاده از الگوریتم شبکه عصبی مبتنی بر سری زمانی مشخص می شود.

### مروری بر کارهای صورت گرفته

در سالهای اخیر، تحقیقات زیادی پیرامون ابعاد مختلف خانه هوشمند از قبیل امنیت، مدیریت انرژی و شناسایی رفتار کاربران مطرح شده است (Hasan, 2015; Sukanya P, 2013; U.A.B.U.A. Bakar 2016). در بخش شناسایی رفتار، برخی تحقیقات به شناسایی رفتار غیر معمول کاربر با استفاده از تشخیص سقوط و برخی با استفاده از الگوریتم های مختلف داده کاوی و تحلیل فعالیت های قبلی کاربر پرداخته اند.

راه رفتن سالمندان از اهمیت خاصی برخوردار است و زمین خوردن آنها می تواند موجب شکستن استخوان لگن شود، به حدی که سالانه ۲۰ درصد از سالمندان به دلیل شکستگی لگن، جان خود را از دست می دهند (Cameron et al., 2010). در تشخیص سقوط از روش های مختلفی استفاده می شود که اغلب این روش ها با استفاده از حسگرهای پوشیدنی است؛ در ادامه به برخی از این روش ها اشاره می شود.

در مقاله (Deen, 2015)، با استفاده از ژيروسکوپ و شتاب سنج که در قسمت زانوها و کف پای بیمار نصب کرده، الگوی حرکتی او را تشخیص داده و از روی روش راه رفتن فرد، بیماری وی توسط پزشک تشخیص داده می شود؛ در واقع در از روی سیگنالهای دریافتی و تطبیق الگوی حرکتی بیمار با الگوهای حرکتی، نتیجه اعلام می شود. در مقاله (Jin et al., 2014) نیز با استفاده از همین حسگرها الگوی راه رفتن در سه گروه سنی زیر ده سال (کودکان)، بین ۲۰ تا ۶۰ سال (بزرگسال) و ۷۰ تا ۸۰ سال (سالمند) را با استفاده از الگوریتم K-means شناسایی کرده است.

مقاله (Thirawut Nilpanapan, 2016) با تکیه بر این موضوع که راه رفتن می تواند وضعیت سلامت فرد را مشخص کند، یک کفش طراحی کرده است و در آن از ۴ حسگر حساس به فشار (در کف پا، پشت پا، قوس بیرونی و پاشنه پا) و یک انتقال دهنده ی داده ی بی سیم (که روی استخوان قوزک قرار می گیرد) استفاده شده است. سپس از روی الگوی راه رفتن بیان شده در مقاله ی (Donkrajang, Watthanawisuth, Mensing, & Kerdcharoen, 2012) وضعیت فرد (راه رفتن عادی، راه رفتن غیر عادی، نشست و ایستادن) مشخص می شود.

البته سنسورهای پوشیدنی حسگرهای پوشیدنی مشکلاتی از قبیل فراموشی در پوشیدن مجدد آنها و هم چنین آزار دهنده بودن آنها برای کاربران می باشد. مورد اول باعث می شود که عملاً این حسگرها برای بیماران آلزایمری قابلیت استفاده نداشته باشند (K. S. Gayathri, 2015). برخی تحقیقات نیز برای تشخیص سقوط سالمند از حسگرهای غیر پوشیدنی استفاده کرده اند. در مقاله ی (Mokhtari, Zhang, & Fazlollahi, 2017)، از تکنولوژی UWB<sup>۱</sup> برای شناسایی سقوط استفاده شده است به این نحو که یک حسگر UWB که شامل فرستنده و گیرنده است، روی سقف نصب می شود تا زمین خوردن را تشخیص دهد.

البته سنسورهای پوشیدنی حسگرهای پوشیدنی مشکلاتی از قبیل فراموشی در پوشیدن مجدد آنها و هم چنین آزار دهنده بودن آنها برای کاربران می باشد و این موارد سبب می شود عملاً این حسگرها برای افرادی مثل بیماران آلزایمری قابلیت استفاده نداشته باشند (K. S. Gayathri, 2015).

در شاخه ی تشخیص فعالیت کاربر نیز از الگوریتم های متفاوتی استفاده می شود که مورد بررسی قرار گرفته اند. در شاخه ی تشخیص فعالیت کاربر نیز از الگوریتم های متفاوتی استفاده می شود که مورد بررسی قرار گرفته اند. در مقاله (Lapalu, Bouchard, Bouzouane, 2013) از الگوریتم Flocking برای تشخیص رفتار کاربر استفاده کرده و بیان کرده که مزیت این الگوریتم نسبت به روش های دیگر عدم نیاز به تعیین تعداد خوشه ی اولیه است. در مقاله (Labiba Gillani Fahad, 2014)، از یک الگوریتم ترکیبی به نام ۲AR-CBC استفاده شده است. در این روش، ابتدا با استفاده از الگوریتم PCA یک سری ویژگی ها انتخاب می شوند، بعد با استفاده از الگوریتم K-means روی داده ها خوشه بندی انجام می شود. در انتها برای ایجاد دقت بیشتر، در هر خوشه با استفاده از الگوریتم K-NN دسته بندی انجام می شود. در مقاله (Sukanya P, 2013)، بیان شده که به علت اینکه کاربران یک سلسله مراتبی از فعالیت ها را

<sup>۱</sup> Ultra-Wide Band

<sup>۲</sup> Activity Recognition approach by clustering and classification

برای یک کار انجام می دهند خوشه بندی به تنهایی، برای مدل کردن رفتار کاربر مناسب نیست. در این مقاله از یک روش ترکیبی جدید برای خوشه بندی به نام K-pattern clustering استفاده کرده است؛ در این روش بعد از یک پیش پردازش روی داده های خام اولیه، داده ها به الگوریتم FP-Growth داده می شوند تا الگوهای مکرر در بین داده ها، شناسایی شوند. در مرحله ی بعد، الگوهای بدست آمده به یک الگوریتم خوشه بندی داده می شوند تا فعالیت ها را خوشه بندی کند و در مرحله نهایی، از الگوریتم شبکه عصبی برای پیش بینی رفتار بعدی کاربر استفاده می شود.

مقاله (Suryadevara, Gaddam, Rayudu, & Mukhopadhyay, 2012)، برای شناسایی رفتار فرد از روش قطعه بندی متن که در مقاله (Utiyama & Isahara, 2001) مطرح شده، استفاده کرده است. در این روش قطعه بندی هر کدام از حسگرها و فعالیت ها به حروف نگاشت می شوند و بعد از بدست آمدن یک متن، بیشترین احتمال قسمتی از متن که بیشترین تکرار را دارد به عنوان دنباله ای برای انجام آن فعالیت انتخاب می شود؛ نام این روش SAPM (Sensor Activity Pattern Matching) است. برای تشخیص غیر طبیعی بودن یک فعالیت هم، دنباله حاصل شده از مرحله قبل که بیانگر نوع هر فعالیت بود در درختی که از قبل با استفاده از دنباله های طبیعی حاصل شده، قرار می گیرد و با الگوریتم Apriori، در صورتی که دنباله مغایر با دنباله های درخت باشد، غیر طبیعی تشخیص داده می شود.

در مقاله (Yu-Ling Hsueh, 2015)، بررسی کرده که امکان دارد در یک خانه بیش از یک فرد زندگی کند و برای برطرف کردن این مشکلات از دوربین های فیلم برداری در سه بعد استفاده می کند و با پردازش این فیلم ها سرعت، نوع رفتار و سایر ویژگی های هر کاربر را به طور مجزا بدست می آورد. با استفاده از این ویژگی ها شبکه های بیزین مختلف که از این ویژگی ها حاصل می شوند، بدست می آیند و بهترین مدل با استفاده از الگوریتم هایی مثل الگوریتم تپه نوردی که در این مقاله از آن استفاده شده، استخراج می شود. حال با استفاده از مدل حاصله و فرمول های الگوریتم شبکه بیزین، احتمالات وقوع پیشامدهای مختلف محاسبه می شوند.

در مقاله (Anthony Fleury, 2010)، از الگوریتم SVM که برای دسته بندی داده ها کارایی دارد، استفاده شده است؛ به این صورت که ابتدا با استفاده از الگوریتم PCA، یک سری از ویژگی ها انتخاب شده و بعد از نرمال کردن داده ها الگوریتم مذکور روی داده ها اعمال می شود. یکی دیگر از روشهای تشخیص فعالیت کاربر که در مقاله (Medjahed, Istrate, Boudy, & Dorizzi, 2009) به آن اشاره شده، استفاده از منطق فازی می باشد. روش کار به این نحو است که هر کدام از فعالیت ها طبق بازه های زمانی مختلف موجود در شبانه روز، به زمانی اختصاص پیدا می کنند و با استفاده از قوانین تعریفی، نوع فعالیت پیش بینی می شود.

در مقاله (Ahmad Lotfi, 2012)، از ESN<sup>۳</sup> برای پیش بینی مقادیر فعالیت های یک فرد استفاده شده؛ مزیت این روش نسبت به روش های قبل در این است که داده های ورودی می توانند در هر زمانی به سیستم وارد شوند در حالیکه در رویکردهای قبلی داده ها باید در یک زمان وارد سیستم می شدند.

درمقاله ی (Vázquez & Kastner, 2011)، مقایسه ای بین انواع روش های خوشه بندی SOM<sup>۴</sup>، XSOM<sup>۵</sup>، خوشه بندی فازی C-means، K-means، K-means با تکرار دو بخشی، خوشه بندی گراف و SVC<sup>۶</sup> (طبق داده های ارائه شده در آن) انجام شده است. در دو روش اول- یعنی SOM و XSOM- تعداد خوشه های ایجاد شده، حتما نباید مساوی تعداد خوشه های تعریف شده توسط ما باشد و این مقدار تعریف شده، تنها بیشترین تعداد خوشه را تعیین می کند؛ تنها تفاوت بین این دو روش آن است که XSOM داده های خارج از محدوده را هم شناسایی می کند ولی در آزمایش انجام شده، این دو روش نتایج مشابهی داشتند. بین خوشه بندی فازی C-means و XSOM نتایج خوشه بندی فازی بهتر است و این مسئله به دلیل خوشه بندی غیر قطعی در آن می باشد. بین سه روش مقایسه شده و K-means، به دلیل آنکه این روشها تعداد خوشه ها را محدود نمی کنند مناسب تر از K-means هستند. SVC هم تنها خوشه های بدیهی را شناسایی کرده است. البته مشکلات مربوط به کارایی در مقایسه با مشکلات دنیای واقعی، جزئی هستند؛ چون در دنیای واقعی ابزارهای خوشه بندی یکبار در روز و در یک بازه زمانی اجرا می شوند، در حالی که مشخصه های قبلی در حال استفاده هستند.

Echo State Network<sup>3</sup>  
Self-Organizing Maps<sup>4</sup>  
eXclusive Self-Organizing Maps<sup>5</sup>  
Support Vector Clustering<sup>6</sup>

در مقاله ی مروری (Shaoen Wu, 2016)، با چند روش فعالیت بعدی کاربر را پیش بینی کرده و بیان کرده که ما باید یک زمان آستانه مشخص کنیم تا اگر فعالیت پیش بینی شده تا آن زمان اتفاق نیافتاد، یک پیغام ارسال شود. روش های استفاده شده در این مقاله عبارتند از: Active LeZi، Flocking، SPEED، Nash H-Learning و الگوریتم Apriori. مدل Active LeZi یک درخت را به ۲۴ زیر درخت تقسیم می کند و بعد از تجزیه، هر فعالیت بر اساس اینکه در چه ساعتی رخ داده، در زیر درخت همان ساعت قرار می گیرد. SPEED نیز با درخت کار می کند. Nash H-Learning نسبت به بقیه مزیتی دارد و آن است که از این الگوریتم اساساً برای پیش بینی مکان چند کاربر در خانه ی هوشمند استفاده می شود.

در مقاله (K. S. Gayathri, 2015; K.S.Gayathri, 2016)، از یک روش سلسله مراتبی برای تشخیص فعالیت ها و میزان غیر عادی بودن آنها استفاده کرده است. چارچوب سلسله مراتبی به این صورت طراحی شده که فاکتورهای با اولویت بالاتر در لایه های پایین تر هستند و هر لایه در صورتی قابل اجرا است که لایه ی پایین تر گزارش غیر عادی بودن آن فعالیت را ندهد. در هر لایه، برای خروجی گرفتن از آن، از یکی از الگوریتم های هوش مصنوعی به نام MLNY استفاده کرده است؛ مزیت این الگوریتم آن است که در هر لایه، بر حسب ساختار تعریف شده برای آن، هم می توان از قوانین نرم\_ قوانینی که سیستم از روال موجود در داده ها به دست آورده است\_ و هم از قوانین سخت\_ قوانینی که توسط افراد خبره تعریف می شود\_ استفاده کرد.

در (Eunju Kim, 2010) از روش HMM برای شناسایی فعالیت ها استفاده شده است. در روش سلسله مراتبی که در قبل بیان شد، به جای MLN از HMM در هر لایه استفاده کرده بود ولی استفاده از این روش را مناسب نمی دانست، چون در HMM از قوانین سخت استفاده نمی شود

#### یافته ها

تشخیص حالت غیر عادی در خانه هوشمند، به دلیل اینکه فردی که قرار است هشدار را دریافت کند در خارج از منزل و یا یک مکان دور است، باید با دقت بسیار بالایی صورت بگیرد و چون این لایه تشخیص فعالیت را بر عهده دارد و این شناسایی، پایه ای برای تشخیص حالت غیر عادی محسوب می شود، بالا بودن دقت در این لایه بسیار حائز اهمیت است و گرنه فرض اولیه \_ فعالیت تشخیص داده شده\_ دچار مشکل می شود. هم چنین محدود نکردن فعالیت ها ی کاربر به چند فعالیت از مواردی هستند که باید برای عملیاتی کردن و شبیه سازی بهتر سیستم های خانه هوشمند با زندگی واقعی افراد، در نظر گرفته شوند.

هر فردی در زندگی روزمره یک روال مشخصی در انجام کارها دارد، برای مثال در حدود ساعت ۲۲ تا ۲۴ شب می خوابد، صبح ها در ساعت ۶ تا ۸ صبح از خواب بیدار می شود، در شبانه روز سه وعده غذا تهیه می کند و بعد آن غذا را می خورد و همین باعث می شود که الگوی زمانی نسبتاً خاصی را دنبال کند؛ از طرفی برای انجام هر کار حسگرها به ترتیب خاصی روشن و خاموش می شوند. به همین منظور در این لایه، شماره حسگر بعد از انجام پیش پردازش و تبدیل به داده های عددی به الگوریتم سری زمانی با استفاده از شبکه ی عصبی داده می شود و در آن بر مبنای سری زمانی پیش بینی صورت می گیرد.

**جدول 1.** ماتریس درهم ریختگی الگوریتم شبکه عصبی مبتنی بر سری زمانی به همراه معیارهای Precision، F-measure و Accuracy برای هر فعالیت

	"Relax"	"Sleeping"	"Bed_to_Toilet"	"Meal_Preparation"	"Work"	"Eating"	"Leave_Home"	"Enter_Home"	"Housekeeping"	"Wash_Dishes"	accuracy
"Relax"	1126	9	0	0	1	0	5	2	0	0	0.985
"Sleeping"	0	8247	11	0	0	2	15	1	5	0	0.996

"Bed to Toilet"	0	0	94	10	0	0	0	0	0	0	0.904
"Meal Preparation"	0	10	7	72	1	1	3	0	2	0	0.75
"Work"	0	0	0	0	123	0	0	0	1	0	0.992
"Eating"	0	3	0	0	0	305	0	0	2	0	0.984
"Leave Home"	9	12	6	0	0	7	6958	0	2	0	0.995
"Enter Home"	0	1	0	0	0	0	3	176	0	0	0.978
"Housekeeping"	0	0	0	0	0	1	11	0	720	0	0.984
"Wash Dishes"	8	0	0	0	0	2	7	4	2	43	0.652
Precision	0.99	0.996	0.797	0.878	0.984	0.959	0.994	0.9617	0.981	1	
F-measure	0.99	0.996	0.847	0.809	0.988	0.971	0.994	0.9697	0.982	0.789	

در جدول ۱ ماتریس در هم ریختگی حاصل از اجرای این الگوریتم موجود است؛ همانطور که مشاهده می شود ستون آخر دقت تشخیص هر فعالیت (Accuracy ۸) را به صورت مجزا بیان کرده و دو سطر آخر هم به ترتیب معیار Precision<sup>۹</sup> و F-measure محاسبه شده است. سلول های موجود روی قطر اصلی جدول که با رنگ دیگر مشخص شده اند، تعداد پیش بینی های درست الگوریتم از هر فعالیت را نشان می دهند که با توجه به دقت تشخیص می بینیم که دقت تشخیص در اغلب فعالیت ها بسیار بالا است، دقت کلی تشخیص هم ۰,۹۹ است که می توان گفت تقریباً تمامی فعالیت ها به درستی تشخیص داده شده اند.

### بحث و نتیجه گیری

در این پژوهش ابتدا مروری بر کارهای صورت گرفته در زمینه ی تشخیص عملکرد کاربر در خانه ی هوشمند که شامل دو زیر مجموعه تشخیص سقوط و شناسایی فعالیت می شود، صورت گرفت. در ادامه هم از الگوریتم سری زمانی برای شناسایی فعالیت کاربر استفاده شد که دقت بسیار بالایی را در تشخیص نشان می دهد و نسبت به الگوریتم های استفاده شده در پژوهش های پیشین بسیار بهتر و با دقت بیشتری عمل می کند.

### منابع

- Ahmad Lotfi, C. L., S. M. Mahmoud, M. J. Akhlaghinia. (2012). Smart homes for the elderly dementia sufferers: identification and prediction of abnormal behavior. *Springer*.
- Allen, K. (2018). Deaths From Falls by Older Adults Sharply Increase. Retrieved from <https://www.aarp.org/health/conditions-treatments/info-2018/falling-deaths-surge-for-elderly.html>
- Anthony Fleury, M. V., Norbert Noury. (2010). SVM-Based Multimodal Classification of Activities of Daily Living in Health Smart Homes: Sensors, Algorithms, and First Experimental Results. *IEEE, 14*.
- Association, A. s. (2012). Alzheimer's disease facts and figures Retrieved from [https://www.alz.org/downloads/facts\\_figures\\_2](https://www.alz.org/downloads/facts_figures_2)
- Cameron, I. D., Chen, J. S., March, L. M., Simpson, J. M., Cumming, R. G., Seibel, M. J., & Sambrook, P. N. (2010). Hip fracture causes excess mortality owing to cardiovascular and infectious disease in institutionalized older people: A prospective 5-year study. *Journal of Bone and Mineral Research, 25*(4), 866-872.
- Deen, M. J. (2015). Information and communications technologies for elderly ubiquitous healthcare in a smart home. *Springer*.
- Donkrajang, W., Watthanawisuth, N., Mensing, J., & Kerdcharoen, T. (2012). *Development of a wireless electronic shoe for walking abnormalities detection*. Paper presented at the Biomedical Engineering International Conference (BMEiCON), 2012.
- Eunju Kim, S. H., Diane Cook. (2010). Human Activity Recognition and Pattern Discovery. *IEEE*.
- Hasan, M. M. H. M. F. R. (2015). *Towards an Analysis of Security Issues, Challenges, and Open Problems in the Internet of Things*. Paper presented at the 2015 IEEE World Congress on Services, New York, NY, USA.

<sup>۸</sup> دقت

<sup>۹</sup> صحت

- Jin, B., Thu, T. H., Baek, E., Sakong, S. H., Xiao, J., Mondal, T., & Deen, M. J. (2014). Walking-age analyzer for healthcare applications. *IEEE journal of biomedical and health informatics*, 18(3), 1034-1042.
- K. S. Gayathri, S. E., Balaraman Ravindran. (2015). Hierarchical activity recognition for dementia care using Markov Logic Network. *Springer*, 19(2).
- K.S.Gayathri, K. S. E. (2016). *Intelligent Decision Support System for Dementia Care Through Smart Home*. Paper presented at the 6th International Conference On Advances In Computing & Communications, India.
- Labiba Gillani Fahad, S. F. T., Muttukrishnan Rajarajan. (2014). *Activity Recognition in Smart Homes using Clustering based Classification*. Paper presented at the 22nd International Conference on Pattern Recognition (ICPR), Stockholm.
- Lapalu, J., Bouchard, K., Bouzouane, A., Bouchard, B., & Giroux, S. (2013). Unsupervised Mining of Activities for Smart Home Prediction. *Procedia Computer Science*, 19, 503-510.  
doi:<https://doi.org/10.1016/j.procs.2013.06.067>
- Medjahed, H., Istrate, D., Boudy, J., & Dorizzi, B. (2009). *Human activities of daily living recognition using fuzzy logic for elderly home monitoring*. Paper presented at the Fuzzy Systems, 2009. FUZZ-IEEE 2009. IEEE International Conference on.
- Mokhtari, G., Zhang, Q., & Fazlollahi, A. (2017). *Non-wearable UWB sensor to detect falls in smart home environment*. Paper presented at the Pervasive Computing and Communications Workshops (PerCom Workshops), 2017 IEEE International Conference on.
- Organization, W. H. (2015). 10 facts on ageing and the life course. [http://www.who.int/features/factfiles/ageing/ageing\\_facts/en/index.html](http://www.who.int/features/factfiles/ageing/ageing_facts/en/index.html).
- Shakeri, S. (2017). A Smartphone-based Fall Detection System using Accelerometer and Microphone. *Iranian Journal of Biomedical Engineering*.
- Shaoen Wu, J. B., Rendall, Matthew J. Smith, Shangyu Zhu, Junhong Xu, Honggang Wang, Qing Yang, Pinle Qin. (2016). Survey on Prediction Algorithms in Smart Homes. *IEEE*.
- Sukanya P, G. K. S. (2013). An Unsupervised Pattern Clustering Approach for Identifying Abnormal User Behaviors in Smart Homes. *IJCSN*, 2(3).
- Suryadevara, N., Gaddam, A., Rayudu, R., & Mukhopadhyay, S. (2012). Wireless sensors network based safe home to care elderly people: Behaviour detection. *Sensors and Actuators A: Physical*, 186, 277-283.
- Thirawut Nilpanapan, T. K. (2016). *Social data shoes for gait monitoring of elderly people in smart home*. Paper presented at the 9th Biomedical Engineering International Conference (BMEiCON).
- U.A.B.U.A. Bakar , H. G., S.F. Hasanm , S.C. Mukhopadhyay. (2016). Activity and Anomaly Detection in Smart Home: A Survey. *Springer*.
- Utiyama, M., & Isahara, H. (2001). *A statistical model for domain-independent text segmentation*. Paper presented at the Proceedings of the 39th Annual Meeting on Association for Computational Linguistics.
- Vázquez, F. I., & Kastner, W. (2011). *Clustering methods for occupancy prediction in smart home control*. Paper presented at the Industrial Electronics (ISIE), 2011 IEEE International Symposium on.
- Yu-Ling Hsueh, N.-H. L., Chia-Che Chang, Oscar T.-C. Chen, Wen-Nung Lie. (2015). *Abnormal Event Detection Using Bayesian Networks at a Smart Home*. Paper presented at the 8th International Conference on Ubi-Media Computing (UMEDIA).